

Wikipedia 기반 RAG System

document chunking, embedding

서한녕

Index

1. pdf text extraction
2. chunking
3. sparse retrieval
4. dense retrieval
5. comparison

pdfplumber

ABSTRACT

As one of the most advanced techniques in AI, Retrieval-Augmented Generation (RAG) can offer reliable and up-to-date external knowledge, providing huge convenience for numerous tasks. Particularly in the era of AI-Generated Content (AIGC), the powerful capacity of retrieval in providing additional knowledge enables RAG to assist existing generative AI in producing high-quality outputs. Recently, Large Language Models (LLMs) have demonstrated revolutionary abilities in language understanding and generation, while still facing inherent limitations, such as hallucinations and out-of-date internal knowledge. Given the powerful abilities of RAG in providing the latest and helpful auxiliary information, Retrieval-Augmented Large Language Models (RA-LLMs) have emerged to

1 INTRODUCTION

As one of the most fundamental data mining techniques, retrieval aims to understand the input query and extract relevant information from external data sources [24, 30, 67, 140]. It has found extensive application in various fields [8, 28, 106, 179], such as search, question answering, and recommender systems. For instance, search engines (e.g., Google, Bing, and Baidu) are the most successful applications of retrieval in the industry; they can filter and retrieve the most relevant web pages or documents that can match a user's query [19, 179], enabling users to find the desired information effectively. Meanwhile, retrieval models, through effective data maintenance in external databases, can provide faithful and timely external knowledge, thereby serving vital functions in

nAsoneofthemostadvancedtechniquesinAI

Anillustrationofdifferentrainingmethods Retrieval

Retrieval-Augmented Asoneofthemostfundamentaldataminingtechniques

텍스트 추출 문제점

- 단어 사이 공백이 많이 사라짐
- Asoneofthemostadvanced...처럼 문장이 붙음
- ABSTRACT문단에서 INTRODUCTION문단으로 넘어가버림
- 추가 cleaning 없이는 RAG chunk로 쓰기 애매함

pdfreader

ag2_pages_pdfreader.jsonl

```
ndemanding\nhigh\nfor\nthe\nlatest\nand\nnr\nreliable\nknkno\nwle\nndge\nsuch\nnas  
ght\nstill\nnot\ngenerate\naccurate\nnr\nesp\nnonses\nwhen\nnfacing\nne\nnw\ntask  
\n,\n117\n,\n1168\n,\n1196\n,\n1197\n,\n,\nwher\nne\nnpassages\nnar\nne\nnsp\nne  
base\nand\nnr\nnepr\nesent\nknkno\nwle\nndge\nwith\nntity\nmemor\nny\n.\nAt\nna\nnm  
e\nval\nand\ngeneration\nstages\n[\n1173\n],\nparticularly\nfor\nnclose\nnd-sour  
ctiv\neness\nfor\nndiffer\nnent\nnfunctions\nsuch\nnas\nknkno\nwle\nne\nndge\nnaugment  
for\nthe\ngeneration\nnmo\nndel\n.\nDespite\nthe\nneffe\nnctiv\neness\n,\nsuch\nninteg  
ne\nnquency\n(\nalso\ncalle\nnd\nnr\netrie\nval\nnstride\n)\nis\nnan\nnimp\nnortant\nn  
gr\nnegate\nnd\nt\nno\ngenerate\nlong-form\nansw\nners\n.\n4.1.2\nRetrie\nval-Guide  
n.g.\n,\nBERT\n[\n25\n,\n64\n,\n123\n],\nCLIP\n[\n113\n],\nT5\n[\n116\n])\ncan  
natural\nand\nconv\nersational\nmanner\n[\n87\n].\nDiffer\nnent\nnfr\nnom\nthe\nn  
on\nof\nnfinancial\nsentiment\nanalysis\n.\nIn\nnaddition\n,\nfinancial\nQ\nA\nnis\nn  
u\n,\nMike\nLe\nnwis\n,\nLuke\nZettlemo\nny\nner\n,\nand\nMarjan\nGhazvininejad\n.\n2  
is\nBr\nno\nckett\n,\nMing\nW\nnei\nChang\n,\nBill\nDolan\n,\nJianfeng\nGao\n,\nW\nne  
chen\nLiu\n,\nYiqi\nW\nang\n,\nW\nnenqi\nFan\n,\nXiaorui\nLiu\n,\nY\nnaxin\nLi\n,\nSha  
stillation\n.\nXiv\npr\nneprint\nXiv:2405.03085\n(2024)\n.\n[134]\nPeng\nnShi  
,\nnei\nZhou\n,\nHua\nnOuyang\n,\nJianhui\nChen\n,\nChangsung\nK\nang\n,\nHongb\nno\nDeng  
nei\nZhou\n,\nHua\nnOuyang\n,\nJianhui\nChen\n,\nChangsung\nK\nang\n,\nHongb\nno\nDeng
```

텍스트 추출 문제점

- 줄바꿈이 과도하게 많음
- 단어가 글자 단위로 쪼개짐
- 공백 수가 0으로 잡힐 정도로 구조가 이상함
- 검색용 tokenizer가 제대로 작동하기 어려움
- cleaning을 많이 해도 원문 복원이 쉽지 않음

pypdf

```
ages_pypdf.jsonl
tion of the survey to appear at KDD 2024 [33]\n1 INTRODUCTION\nAs c
significantly\nhinders the widespread adoption of LLMs in various
quence into\nanother, such as machine translation, summarization, a
[54]. On top of offering supplementary to en\nhance the input of
e in cases requiring rare patterns or out-of-domain data [62],\nn
ten Context Adapter (PRCA) that enables\nto fine-tune the lightweig
additional RAG, Internet search\nhas been leveraged more as the ret
the number of retrieved documents, since\nthe concatenated new inp
ecting the overall performance of RAG\nmodels [117]. Retrieval frequ
e given context and question.\nSKR [159] proposes guiding LLMs to
sequential training involves coordinated training of the retriever
ditional manner [87]. Different from the QA\nsystem, ChatBot focus
ant knowledge from financial docu\nments. As professional document
for Machine Translation.\nIn ACL (Findings). Association for Comput
n-tau Yih, and Michel Galley. 2018. A knowledge-grounded neural co
Yiqi Wang, Wenqi Fan, Xiaorui Liu, Yaxin Li, Shaili Jain, Yunhao
print arXiv:2405.03085 (2024).\n[134] Peng Shi, Rui Zhang, He Bai,
Ouyang,\nJianhui Chen, Changsung Kang, Hongbo Deng, Chikashi Noba
```

텍스트 추출 장점

- 세 라이브러리 중 문장 흐름이 가장 자연스러웠다.
- 단어 사이 공백이 가장 잘 유지되었다.
- BM25 / TF-IDF 같은 단어 기반 검색에 적합했다.
- pdfplumber처럼 단어가 과도하게 붙지 않았다.
- pdfreader처럼 글자 단위로 쪼개지지 않았다.
- 추가 cleaning 없이 chunking 단계로 넘길 수 있었다.

JSONL 선택 이유

기존 JSON

```
[  
{  
  "page": 1,  
  "text": "1페이지 내용..."  
},  
{  
  "page": 2,  
  "text": "2페이지 내용..."  
}]
```

]일반 JSON은 전체 record를 하나의 배열로 저장하기 때문에 보통 전체를 한 번에 읽어 처리합니다.

JSONL (선택)

```
{"page": 1, "text": "..."}  
  
{"page": 2, "text": "..."}  
  
{"page": 3, "text": "..."}  
  

```

✓ 줄바꿈 없는 단일 행 구조 (Line-by-Line)

JSONL은 한 줄에 하나의 chunk record를 저장, 필요한 chunk를 한 줄씩 읽으며 확인하거나 처리

이런 방식이 RAG의 chunk 단위 처리 흐름에 적합

메모리에 다 올릴 필요가 없어서 jsonl이 더 적합

Query : retrieval granularity chunk entity

BM25 / TF-IDF

Token retrieval ~

text chunk ~

mainstream retrieval text granularity in RAG.

Another major retrieval granularity proposed in RAG is entity retrieval.

세부 granularity 내용 (token retrieval, entity retrieval)

BM25/TF-IDF는 retrieval granularity, chunk, entity 단어들에 실제로 많이 등장하는 chunk를 선호
그래서 chunk, entity, token retrieval이 많이 나오는 p5_c3을 선택

Dense

"Retrieval granularity denotes the retrieval unit in which the corpus is indexed, e.g., document, passage, token, or other levels like entity."

retrieval granularity 정의 구절을 선택함

Query : Self-RAG

BM25 / TF-IDF

Recently, Self-RAG [5] has greatly made a notable impression by incorporating a self-reflective mechanism.

Specifically, Self-RAG reflects on whether retrieved information is helpful and judges the reliability of retrieved information, thereby greatly improving the verification accuracy.

p12_c4는 본문에서 Self-RAG를 설명하는 부분

Dense

Dense → [5] Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection.

In The Twelfth International Conference on Learning Representations.

이 chunk는 Self-RAG 논문의 참고문헌 항목

관련은 있지만, Self-RAG의 내용 설명이라기보다는 citation 정보

Query : How does RAG reduce hallucination?

BM25 / TF-IDF

LLMs still suffer from intrinsic limitations,
such as the lack of domain-specific knowledge,
the problem of “hallucination” ...
LLM에 hallucination 문제가 있다
해결 방식 설명은 부족

Dense

alleviate the limitations of LLMs, such as hallucination
and out-of-date internal knowledge, by leveraging
retrieval to provide the latest auxiliary information

RAG는 retrieval을 통해 최신/외부 보조 정보를
제공하고, LLM이 그 정보를 활용하게 해서
hallucination과 outdated knowledge 문제를 완화한다.

이 사례는 자연어 질문에서는 Dense retrieval이 keyword matching보다 질문 의도에 더 가까운 chunk를 찾을 수 있음을 보여줌

Query : What are training-free RAG methods?

BM25 / TF-IDF

training-free approaches usually directly leverage retrieved information

during the inference time by integrating the retrieved knowledge into the prompt

BM25는 methods 분류가 더 직접적으로 나오는 chunk를 선택했다.

4.1 Training-free

enhancing LLMs with retrieval mechanisms,

enabling them to dynamically acquire new knowledge from external sources

without extra training processes TF-IDF는 `Training-free` section의 시작 chunk를 선택했다.

Dense

Based on whether training is required or not,

existing RAG methods can be categorized into two main classes:

train-free approaches and training-based approaches.

Dense는 training 여부에 따른 전체 분류 개요 chunk를 선택했다.

Comparison

Finding: technical term 중심 query가 많아서 sparse retrieval이 더 안정적으로 보였다.

BM25 / TF-IDF

주요 특징

- 정확한 용어와 section을 잘 찾음

Dense

주요 특징

- 의미적으로 관련된 넓은 context를 찾음
- Broad query에서 Dense가 introduction/overview로 가는 경우가 있음

결론

BM25 / TF-IDF

1. 대부분 비슷한 검색 경향성 보유

- 둘 다 **sparse retrieval** 기술을 활용하여 쿼리 키워드와 청크 텍스트의 직접적인 일치율 주요하게 평가

2. 명확한 기술 용어 쿼리에서의 강세

- **Self-RAG, query rewriting** 등 정확한 단어 매칭이 요구되는 태스크에서 압도적인 검색 안정성을 보임

Dense Retrieval

1. 넓은 맥락 정보 파악 능력

- 의미가 유사하거나 인접한 섹션을 잘 탐색하나, 가끔 요약/참고문헌 영역으로 이탈(drift)하는 한계를 보임

2. 구어체 및 자연어 쿼리 강점과 극단성

- 일상적인 질문 방식(paraphrased query)에서 뛰어난 검색결과를 내는 한편, 용어가 극단적으로 멀어지면 세 방법론 모두 검색에 실패하기도 했다

'different' 결과가 반드시 실패는 아니다

retrieval granularity, training strategy 등의 미세 조건 차이로 인해 기준 문서의 바로 인접한 청크(Chunk)를 선택한 정상적인 케이스가 많이 포함되어 있어, 다른 결과가 곧 실패를 뜻하지는 않음

한계점

1. Query 수 부족
2. Query 편향
3. Chunk size, Chunk overlap 비교 실험 부족
4. dense retrieval 비교 실험 부족